

Analyse en composantes principales

Simon Malinowski

L3 Miage, Univ. Rennes 1

Exemple

	janv	févr	mars	avri	mai	juin	juil	aoû	sept	octo	nove	déce
Bordeaux	5.6	6.6	10.3	12.8	15.8	19.3	20.9	21.0	18.6	13.8	9.1	6.2
Brest	6.1	5.8	7.8	9.2	11.6	14.4	15.6	16.0	14.7	12.0	9.0	7.0
Clermont	2.6	3.7	7.5	10.3	13.8	17.3	19.4	19.1	16.2	11.2	6.6	3.6
Grenoble	1.5	3.2	7.7	10.6	14.5	17.8	20.1	19.5	16.7	11.4	6.5	2.3
Lille	2.4	2.9	6.0	8.9	12.4	15.3	17.1	17.1	14.7	10.4	6.1	3.5
Lyon	2.1	3.3	7.7	10.9	14.9	18.5	20.7	20.1	16.9	11.4	6.7	3.1
Marseille	5.5	6.6	10.0	13.0	16.8	20.8	23.3	22.8	19.9	15.0	10.2	6.9
Montpellier	5.6	6.7	9.9	12.8	16.2	20.1	22.7	22.3	19.3	14.6	10.0	6.5
Nantes	5.0	5.3	8.4	10.8	13.9	17.2	18.8	18.6	16.4	12.2	8.2	5.5
Nice	7.5	8.5	10.8	13.3	16.7	20.1	22.7	22.5	20.3	16.0	11.5	8.2
Paris	3.4	4.1	7.6	10.7	14.3	17.5	19.1	18.7	16.0	11.4	7.1	4.3
Rennes	4.8	5.3	7.9	10.1	13.1	16.2	17.9	17.8	15.7	11.6	7.8	5.4
Strasbourg	.4	1.5	5.6	9.8	14.0	17.2	19.0	18.3	15.1	9.5	4.9	1.3
Toulouse	4.7	5.6	9.2	11.6	14.9	18.7	20.9	20.9	18.3	13.3	8.6	5.5
Vichy	2.4	3.4	7.1	9.9	13.6	17.1	19.3	18.8	16.0	11.0	6.6	3.4
Moyenne	4.0	4.8	8.2	11.0	14.4	17.8	19.8	19.6	17.0	12.3	7.9	4.9
Ecart-type	1.94	1.81	1.48	1.37	1.45	1.73	2.06	1.94	1.79	1.77	1.74	1.89

Questions

- ① Que peux t'on dire de particulier sur Nice ?
- ② Grenoble et Lyon se ressemblent-ils ? Qu'est ce qui les caractérise ?
- ③ En quoi Lille et Nice sont différents ?
- ④ Quelles sont les particularités de Brest ?
- ⑤ Y a t'il des villes qui se ressemblent ?
- ⑥ Quels mois sont liés ?

- 1 Contexte, données, problème
- 2 ACP : objectifs
- 3 Nuage des individus
- 4 Ajustement du nuage d'individus
- 5 Nuages des variables
- 6 Ajustement du nuage des variables
- 7 Déroulement, interprétation d'une ACP

Contexte, données

		Variables				
		1	...	k	...	K
Individus	1	x_{11}	...	x_{1k}	...	x_{1K}
	i	x_{i1}	...	x_{ik}	...	x_{iK}
	I	x_{I1}	...	x_{Ik}	...	x_{IK}
Moy		$\bar{x}_1$	...	$\bar{x}_k$	...	$\bar{x}_K$
Ec. type		σ_1	...	σ_k	...	σ_K

- I individus
- K variables aléatoires **quantitatives**
- Domaine de la statistique exploratoire multidimensionnelle

Exemples

- Université : note de l'étudiant i dans le module k
- Écologie : concentration du polluant k dans la rivière i
- Économie : valeur de l'indicateur k pour une année ou un pays i
- Marketing : valeur de satisfaction k pour la marque i
- Football : statistique k (possession, nb de tirs, etc...) de l'équipe i
- Biologie : mesure k sur l'animal i
- Météorologie : température au mois k de la ville i

Exemple 1

	janv	févr	mars	avri	mai	juin	juil	aoû	sept	octo	nove	déce
Bordeaux	5.6	6.6	10.3	12.8	15.8	19.3	20.9	21.0	18.6	13.8	9.1	6.2
Brest	6.1	5.8	7.8	9.2	11.6	14.4	15.6	16.0	14.7	12.0	9.0	7.0
Clermont	2.6	3.7	7.5	10.3	13.8	17.3	19.4	19.1	16.2	11.2	6.6	3.6
Grenoble	1.5	3.2	7.7	10.6	14.5	17.8	20.1	19.5	16.7	11.4	6.5	2.3
Lille	2.4	2.9	6.0	8.9	12.4	15.3	17.1	17.1	14.7	10.4	6.1	3.5
Lyon	2.1	3.3	7.7	10.9	14.9	18.5	20.7	20.1	16.9	11.4	6.7	3.1
Marseille	5.5	6.6	10.0	13.0	16.8	20.8	23.3	22.8	19.9	15.0	10.2	6.9
Montpellier	5.6	6.7	9.9	12.8	16.2	20.1	22.7	22.3	19.3	14.6	10.0	6.5
Nantes	5.0	5.3	8.4	10.8	13.9	17.2	18.8	18.6	16.4	12.2	8.2	5.5
Nice	7.5	8.5	10.8	13.3	16.7	20.1	22.7	22.5	20.3	16.0	11.5	8.2
Paris	3.4	4.1	7.6	10.7	14.3	17.5	19.1	18.7	16.0	11.4	7.1	4.3
Rennes	4.8	5.3	7.9	10.1	13.1	16.2	17.9	17.8	15.7	11.6	7.8	5.4
Strasbourg	.4	1.5	5.6	9.8	14.0	17.2	19.0	18.3	15.1	9.5	4.9	1.3
Toulouse	4.7	5.6	9.2	11.6	14.9	18.7	20.9	20.9	18.3	13.3	8.6	5.5
Vichy	2.4	3.4	7.1	9.9	13.6	17.1	19.3	18.8	16.0	11.0	6.6	3.4
Moyenne	4.0	4.8	8.2	11.0	14.4	17.8	19.8	19.6	17.0	12.3	7.9	4.9
Ecart-type	1.94	1.81	1.48	1.37	1.45	1.73	2.06	1.94	1.79	1.77	1.74	1.89

Exemple 2, site whoscored.com

Ligue 1 Team Statistics

Summary Defensive Offensive Detailed					
View: Overall Home Away					
R Team	Shots pg	Shots OT pg	Dribbles pg	Fouled pg	Rating
1 Paris Saint Germain	12.7	5.8	11.7	14.1	7.09
2 Marseille	14.8	5.1	13.8	14.7	7.03
3 Lyon	13.6	5.7	10.9	14.2	6.98
4 Monaco	11.9	4.3	11.2	13.5	6.98
5 Saint-Etienne	11.7	4	8.2	12.4	6.90
6 Montpellier	10.4	3.7	9.2	16.2	6.90
7 Caen	12.1	4.1	9.7	10.5	6.87
8 Lille	12.2	3.9	9.5	16.3	6.83
9 Lorient	12.8	4.6	10.1	11.8	6.81
10 Bordeaux	12.8	4.2	7.1	14	6.80
11 Nantes	11.2	3.6	9.9	10.2	6.79
12 Nice	11	3.7	8.3	14.2	6.79
13 Rennes	9.6	3.4	6.7	10.8	6.75
14 SC Bastia	8.4	3.1	7.1	12.9	6.74
15 Toulouse	11.3	3.4	8.8	13.7	6.74
16 Guingamp	9.4	3.7	6.6	14.3	6.71
17 Reims	11.6	3.6	6.6	12.9	6.71
18 Metz	11.8	4	6.8	10.5	6.69
19 Lens	10.6	3.3	7.9	10.9	6.67
20 Evian Thonon Gaillard	8.8	2.8	7.1	11.7	6.67

Shots pg: Shots per game
 Shots OT pg: Shots on target per game
 Dribbles pg: Dribbles per game
Fouled pg: Fouled per game

- 1 Contexte, données, problème
- 2 ACP : objectifs
- 3 Nuage des individus
- 4 Ajustement du nuage d'individus
- 5 Nuages des variables
- 6 Ajustement du nuage des variables
- 7 Déroulement, interprétation d'une ACP

Objectifs de l'ACP

2 axes d'étude

① Étude des individus

- ▶ _____ entre individus
- ▶ _____ des individus
- ▶ **visualisation** synthétique des profils d'individus

Objectifs de l'ACP

2 axes d'étude


① Étude des individus

- ▶ _____ entre individus
- ▶ _____ des individus
- ▶ **visualisation** synthétique des profils d'individus


② Étude des variables

- ▶ liaisons entre variables : _____
- ▶ indicateur synthétique

Exemple 1



Exemple



Température en Janvier

Principe de l'ACP en quelques mots

- Transformer un grand nombre de variables corrélées en un plus petit nombre de variables non corrélées, appelées composantes principales
- Expliquer au mieux la variabilité des données à l'aide de ces composantes
- Trouver la meilleure projection pour compresser un ensemble d'individus de grande dimension en un ensemble d'individus de moindre dimension

Projections orthogonales

Projections orthogonales, suite

2D vers 1D : cf feuille jointe

3D vers 2D : [► Lien](#)

L'ACP... à la main

	Français	Philo	Maths	Physique
Etudiant 1	16	14	8	10
Etudiant 2	17	15	7	9
Etudiant 3	6	8	18	16
Etudiant 4	7	9	17	15

L'ACP... à la main

	Français	Philo	Maths	Physique	$F + M$	$Phi + Phy$
Etudiant 1	16	14	8	10	12	12
Etudiant 2	17	15	7	9	12	12
Etudiant 3	6	8	18	16	12	12
Etudiant 4	7	9	17	15	12	12

L'ACP... à la main

	Français	Philo	Maths	Physique	$F + Phi$	$M + Phy$
Etudiant 1	16	14	8	10	15	9
Etudiant 2	17	15	7	9	16	8
Etudiant 3	6	8	18	16	7	17
Etudiant 4	7	9	17	15	8	16

L'ACP... à la main, vraiment ?

	Janv	Fevr	Mars	Avri	Mai	Juin	juil	Aout	Sept	Octo	Nove	Dece
Janv	1.00	0.97	0.84	0.61	0.36	0.34	0.30	0.41	0.60	0.85	0.95	0.99
Fevr	0.97	1.00	0.93	0.76	0.55	0.52	0.49	0.59	0.76	0.94	0.99	0.97
Mars	0.84	0.93	1.00	0.92	0.77	0.76	0.72	0.80	0.91	0.97	0.93	0.83
Avri	0.61	0.76	0.92	1.00	0.95	0.94	0.91	0.95	0.98	0.91	0.78	0.62
Mai	0.36	0.55	0.77	0.95	1.00	0.99	0.98	0.98	0.94	0.77	0.59	0.38
Juin	0.34	0.52	0.76	0.94	0.99	1.00	0.99	0.99	0.94	0.76	0.57	0.36
juil	0.30	0.49	0.72	0.91	0.98	0.99	1.00	0.99	0.93	0.74	0.55	0.32
Aout	0.41	0.59	0.80	0.95	0.98	0.99	0.99	1.00	0.97	0.81	0.64	0.43
Sept	0.60	0.76	0.91	0.98	0.94	0.94	0.93	0.97	1.00	0.93	0.80	0.62
Octo	0.85	0.94	0.97	0.91	0.77	0.76	0.74	0.81	0.93	1.00	0.96	0.87
Nove	0.95	0.99	0.93	0.78	0.59	0.57	0.55	0.64	0.80	0.96	1.00	0.96
Dece	0.99	0.97	0.83	0.62	0.38	0.36	0.32	0.43	0.62	0.87	0.96	1.00

Besoin d'une méthode automatique

- 1 Contexte, données, problème
- 2 ACP : objectifs
- 3 Nuage des individus**
- 4 Ajustement du nuage d'individus
- 5 Nuages des variables
- 6 Ajustement du nuage des variables
- 7 Déroulement, interprétation d'une ACP


Nuage N_i des individus

	1	...	k	...	K
1	x_{i1}	...	x_{ik}	...	x_{iK}
i					
I					
G_I	$\bar{x}_1$	...	$\bar{x}_k$	...	$\bar{x}_K$

Nuage N_i des individus

	1	...	k	...	K
1					
i					
l					
	x_{i1}	...	x_{ik}	...	x_{iK}
G_l	$\bar{x}_1$	...	$\bar{x}_k$	...	$\bar{x}_K$


Espace des individus : $\mathbb{R}^K$



Nuage N_i des individus

	1	...	k	...	K
1					
i					
l					
G_l	$\bar{x}_1$	...	$\bar{x}_k$	...	$\bar{x}_K$

Espace des individus : $\mathbb{R}^K$




$$d^2(M_i, M_j) = \sum_{k=1}^K (x_{ik} - x_{jk})^2$$

Nuage N_i des individus

	1	...	k	...	K
1					
i					
l					
	x_{i1}	...	x_{ik}	...	x_{iK}
G_l	$\bar{x}_1$	...	$\bar{x}_k$	...	$\bar{x}_K$

Espace des individus : $\mathbb{R}^K$



$$d^2(M_i, M_j) = \sum_{k=1}^K (x_{ik} - x_{jk})^2$$


On appelle inertie du nuage :

$$\frac{1}{l} \sum_{i=1}^l d^2(G_l, M_i) = \frac{1}{l} \sum_{i=1}^l \sum_{k=1}^K (x_{ik} - \bar{x}_k)^2 =$$

Nuage N_i des individus

	1	...	k	...	K
1					
i	x_{i1}	...	x_{ik}	...	x_{iK}
l					
G_l	$\bar{x}_1$	...	$\bar{x}_k$	...	$\bar{x}_K$

Espace des individus : $\mathbb{R}^K$




$$d^2(M_i, M_j) = \sum_{k=1}^K (x_{ik} - x_{jk})^2$$

On veut visualiser ce nuage, en avoir une image approchée respectant sa forme, sa structure

Centrage et réduction



Centrer ne modifie pas la forme du nuage : toujours centrer

$$x_{ik} \leftarrow x_{ik} - \bar{x}_k$$




L'origine est confondue avec le centre de gravité du nuage

Centrage et réduction



Centrage et réduction



Réduire les données est indispensable si les unités de mesure sont différentes d'une variable à l'autre

$$x_{ik} \leftarrow \frac{x_{ik} - \bar{x}_k}{\sigma_k}$$

L'inertie d'un nuage de points centrés réduits vaut K (nb variables)

Exemple


	Janv	Févr	Mars	Avri	Mai	Juin	juil	Août	Sept	Octo	Nove	Déce
Bordeaux	0.84	0.98	1.40	1.33	0.94	0.85	0.52	0.74	0.90	0.84	0.67	0.72
Brest	1.10	0.54	-0.29	-1.30	-1.95	-1.98	-2.06	-1.83	-1.28	-0.18	0.62	1.14
Clermont	-0.71	-0.63	-0.50	-0.50	-0.44	-0.31	-0.21	-0.24	-0.44	-0.63	-0.76	-0.66
Grenoble	-1.28	-0.90	-0.36	-0.28	0.05	-0.02	0.13	-0.03	-0.16	-0.52	-0.82	-1.35
Lille	-0.81	-1.07	-1.51	-1.52	-1.40	-1.46	-1.33	-1.27	-1.28	-1.09	-1.05	-0.71
Lyon	-0.97	-0.85	-0.36	-0.06	0.32	0.38	0.42	0.27	-0.05	-0.52	-0.70	-0.92
Marseille	0.79	0.98	1.20	1.48	1.63	1.71	1.69	1.66	1.63	1.52	1.30	1.09
Montpellier	0.84	1.03	1.13	1.33	1.22	1.31	1.39	1.41	1.30	1.29	1.19	0.87
Nantes	0.53	0.26	0.11	-0.13	-0.37	-0.37	-0.50	-0.50	-0.33	-0.07	0.16	0.35
Nice	1.82	2.03	1.74	1.70	1.56	1.31	1.39	1.51	1.86	2.08	2.05	1.77
Paris	-0.30	-0.41	-0.43	-0.20	-0.09	-0.19	-0.36	-0.45	-0.55	-0.52	-0.47	-0.29
Rennes	0.43	0.26	-0.23	-0.64	-0.92	-0.94	-0.94	-0.91	-0.72	-0.41	-0.07	0.29
Strasbourg	-1.84	-1.85	-1.78	-0.86	-0.30	-0.37	-0.41	-0.65	-1.06	-1.60	-1.74	-1.87
Toulouse	0.37	0.42	0.65	0.45	0.32	0.50	0.52	0.69	0.74	0.55	0.39	0.35
Vichy	-0.81	-0.79	-0.77	-0.79	-0.57	-0.42	-0.26	-0.39	-0.55	-0.75	-0.76	-0.76

Faire une ACP de ce tableau : en obtenir une image approchée la plus fidèle possible

- 1 Contexte, données, problème
- 2 ACP : objectifs
- 3 Nuage des individus
- 4 Ajustement du nuage d'individus**
- 5 Nuages des variables
- 6 Ajustement du nuage des variables
- 7 Déroulement, interprétation d'une ACP


Meilleure représentation axiale

Espace des individus : $\mathbb{R}^K$



Meilleure représentation axiale

Espace des individus : $\mathbb{R}^K$



Objectif : trouver u_1 qui _____
 u_1 est l'axe d'inertie maximum

Premier axe principal u_1

- L'axe u_1 d'inertie maximum est engendré par le _____ de la matrice de corrélation associée à la _____ valeur propre λ_1

Premier axe principal u_1

- L'axe u_1 d'inertie maximum est engendré par le _____ de la matrice de corrélation associée à la _____ valeur propre λ_1
- Cet axe passe par le centre de gravité du nuage de points

Premier axe principal u_1

- L'axe u_1 d'inertie maximum est engendré par le _____ de la matrice de corrélation associée à la _____ valeur propre λ_1
- Cet axe passe par le centre de gravité du nuage de points
- L'inertie expliquée par ce premier axe est égale à λ_1

Premier axe principal u_1

- L'axe u_1 d'inertie maximum est engendré par le _____ de la matrice de corrélation associée à la _____ valeur propre λ_1
- Cet axe passe par le centre de gravité du nuage de points
- L'inertie expliquée par ce premier axe est égale à λ_1
- La part d'inertie expliquée par u_1 est égale à λ_1/K

Première composante principale F_1

Rappel : un individu i est composé de K attributs $x_{i1}, \dots, x_{iK}$, et représente un point dans un espace à K dimensions.

Première composante principale F_1

Rappel : un individu i est composé de K attributs $x_{i1}, \dots, x_{iK}$, et représente un point dans un espace à K dimensions.

La première composante principale F_1 est une **nouvelle variable** dont la valeur pour chaque individu M_i vaut :

- la longueur de la projection de M_i sur le premier axe principal u_1
- le produit scalaire entre $\overrightarrow{OM_i}$ et $\vec{u}_1$

Première composante principale F_1

Rappel : un individu i est composé de K attributs $x_{i1}, \dots, x_{iK}$, et représente un point dans un espace à K dimensions.


La première composante principale F_1 est une **nouvelle variable** dont la valeur pour chaque individu M_i vaut :

- la longueur de la projection de M_i sur le premier axe principal u_1
- le produit scalaire entre $\overrightarrow{OM_i}$ et $\vec{u}_1$

Résultats :


- $E[F_1] = 0$
- $Var[F_1] = \lambda_1$

Meilleure représentation plane



On cherche un plan $P(u_1, u_2)$ qui
maximise $\sum_{i=1}^I OH_i^2$
Plan d'inertie maximale

Meilleure représentation plane



On cherche un plan $P(u_1, u_2)$ qui
maximise $\sum_{i=1}^I OH_i^2$
Plan d'inertie maximale

Résultats :

- l'axe d'inertie maximal est dans le plan d'inertie maximal
- u_2 est l'axe d'inertie maximal avec $u_2 \perp u_1$
- u_2 est engendré par le vecteur propre unitaire de la matrice de corrélation associé à la deuxième plus grande valeur propre λ_2

Le premier plan principal

Le premier plan principal est le plan engendré par les deux premiers axes principaux u_1 et u_2 .

Dans ce plan, chaque point du nuage est représenté par 2 coordonnées : les produits scalaires sur chacun des deux axes principaux.

Inertie expliquée par le premier plan principal : $\lambda_1 + \lambda_2$

Part de l'inertie totale expliquée par le premier plan principal : $\frac{\lambda_1 + \lambda_2}{K}$

Suite d'axes de représentation de N_i

Problème : Trouver une suite d'axes orthogonaux d'inertie maximum

Soit u_s un vecteur unitaire, $s \geq 1$ Soit H_i^s la projection de M_i sur u_s

Je veux trouver u_s tel que $\sum_{i=1}^I (OH_i^s)^2$ soit maximum avec la contrainte

$$u_s \perp u_t, \forall t < s$$

Suite d'axes de représentation de N_i

Problème : Trouver une suite d'axes orthogonaux d'inertie maximum

Soit u_s un vecteur unitaire, $s \geq 1$ Soit H_i^s la projection de M_i sur u_s

Je veux trouver u_s tel que $\sum_{i=1}^I (OH_i^s)^2$ soit maximum avec la contrainte


$$u_s \perp u_t, \forall t < s$$

Solution : u_s est le vecteur propre de la matrice de corrélation associé à la valeur propre de rang s : λ_s


Exemple

	janv	févr	mars	avri	mai	juin	juil	aoû	sept	octo	nove	déce
Bordeaux	5.6	6.6	10.3	12.8	15.8	19.3	20.9	21.0	18.6	13.8	9.1	6.2
Brest	6.1	5.8	7.8	9.2	11.6	14.4	15.6	16.0	14.7	12.0	9.0	7.0
Clermont	2.6	3.7	7.5	10.3	13.8	17.3	19.4	19.1	16.2	11.2	6.6	3.6
Grenoble	1.5	3.2	7.7	10.6	14.5	17.8	20.1	19.5	16.7	11.4	6.5	2.3
Lille	2.4	2.9	6.0	8.9	12.4	15.3	17.1	17.1	14.7	10.4	6.1	3.5
Lyon	2.1	3.3	7.7	10.9	14.9	18.5	20.7	20.1	16.9	11.4	6.7	3.1
Marseille	5.5	6.6	10.0	13.0	16.8	20.8	23.3	22.8	19.9	15.0	10.2	6.9
Montpellier	5.6	6.7	9.9	12.8	16.2	20.1	22.7	22.3	19.3	14.6	10.0	6.5
Nantes	5.0	5.3	8.4	10.8	13.9	17.2	18.8	18.6	16.4	12.2	8.2	5.5
Nice	7.5	8.5	10.8	13.3	16.7	20.1	22.7	22.5	20.3	16.0	11.5	8.2
Paris	3.4	4.1	7.6	10.7	14.3	17.5	19.1	18.7	16.0	11.4	7.1	4.3
Rennes	4.8	5.3	7.9	10.1	13.1	16.2	17.9	17.8	15.7	11.6	7.8	5.4
Strasbourg	.4	1.5	5.6	9.8	14.0	17.2	19.0	18.3	15.1	9.5	4.9	1.3
Toulouse	4.7	5.6	9.2	11.6	14.9	18.7	20.9	20.9	18.3	13.3	8.6	5.5
Vichy	2.4	3.4	7.1	9.9	13.6	17.1	19.3	18.8	16.0	11.0	6.6	3.4
Moyenne	4.0	4.8	8.2	11.0	14.4	17.8	19.8	19.6	17.0	12.3	7.9	4.9
Ecart-type	1.94	1.81	1.48	1.37	1.45	1.73	2.06	1.94	1.79	1.77	1.74	1.89


Exemple



Exemple




Exemple




$cor(k, F_1) = \sqrt{\lambda_1} u_{1k}$. Ici $cor(\text{Janvier}, F_1) = 0.76$

Représentation des variables associée au premier plan de l'ACP




Exemple



Exemple

	janv	févr	nov	déc	moy	ampli	F1	F2
Bordeaux	5.6	6.6	9.1	6.2	13.33	15.4	3.12	-0.11
Brest	6.1	5.8	9.0	7.0	10.77	10.2	-2.27	-4.09
Clermont	2.6	3.7	6.6	3.6	10.94	16.8	-1.73	0.59
Grenoble	1.5	3.2	6.5	2.3	10.98	18.6	-1.53	1.69
Lille	2.4	2.9	6.1	3.5	9.73	14.7	-4.22	-0.6
Lyon	2.1	3.3	6.7	3.1	11.36	18.6	-0.83	1.79
Marseille	5.5	6.6	10.2	6.9	14.23	17.8	4.83	0.83
Montpellier	5.6	6.7	10.0	6.5	13.89	17.1	4.15	0.44
Nantes	5.0	5.3	8.2	5.5	11.69	13.8	-0.28	-1.11
Nice	7.5	8.5	11.5	8.2	14.84	15.2	6.01	-0.79
Paris	3.4	4.1	7.1	4.3	11.18	15.7	-1.24	0.16
Rennes	4.8	5.3	7.8	5.4	11.13	13.1	-1.44	-1.67
Strasbourg	.4	1.5	4.9	1.3	9.72	18.6	-4.11	2.17
Toulouse	4.7	5.6	8.6	5.5	12.68	16.2	1.74	0.14
Vichy	2.4	3.4	6.6	3.4	10.72	16.9	-2.2	0.58



- 1 Contexte, données, problème
- 2 ACP : objectifs
- 3 Nuage des individus
- 4 Ajustement du nuage d'individus
- 5 Nuages des variables**
- 6 Ajustement du nuage des variables
- 7 Déroulement, interprétation d'une ACP


Nuage des variables N_v

	1	...	k	...	K
1			x_{1k}		
i	x_{i1}	...	x_{ik}	...	x_{iK}
I			x_{Ik}		
G_v	0	...	0	...	0
Ecart-type	1	...	1	...	1

Nuage des variables N_v


	1	...	<i>k</i>	...	<i>K</i>
1			x_{1k}		
<i>i</i>	x_{i1}	...	x_{ik}	...	x_{iK}
<i>I</i>			x_{Ik}		
G_V	0	...	0	...	0
Ecart-type	1	...	1	...	1

$$\cos(M_k, M_l) =$$




- 1 Contexte, données, problème
- 2 ACP : objectifs
- 3 Nuage des individus
- 4 Ajustement du nuage d'individus
- 5 Nuages des variables
- 6 Ajustement du nuage des variables**
- 7 Déroulement, interprétation d'une ACP

Ajustement du nuage des variables



Ajustement du nuage des variables



$$\text{Maximiser } \sum_{k=1}^K (OH_k^s)^2 = \sum_k (\cos \theta_k^s)^2 = \sum_k (r(k, v))^2$$

Ajustement du nuage des variables

Soit v_s un vecteur unitaire de la direction de rang s Soit H_k^s la projection de M_k sur v_s

L'axe optimal est tel que $\sum_{k=1}^K (OH_k^s)^2$ maximum, sous la contrainte
 $v_s \perp v_t, \forall t < s$

Ajustement du nuage des variables

Soit v_s un vecteur unitaire de la direction de rang s Soit H_k^s la projection de M_k sur v_s

L'axe optimal est tel que $\sum_{k=1}^K (OH_k^s)^2$ maximum, sous la contrainte

$$v_s \perp v_t, \forall t < s$$

$$\sum_{k=1}^K (OH_k^s)^2 = \sum_k (\cos \theta_k^s)^2 = \sum_k (r(k, v))^2$$

Ajustement du nuage des variables

Soit v_s un vecteur unitaire de la direction de rang s Soit H_k^s la projection de M_k sur v_s


L'axe optimal est tel que $\sum_{k=1}^K (OH_k^s)^2$ maximum, sous la contrainte

$$v_s \perp v_t, \forall t < s$$


$$\sum_{k=1}^K (OH_k^s)^2 = \sum_k (\cos \theta_k^s)^2 = \sum_k (r(k, v))^2$$

On obtient exactement la même chose qu'avec les individus !!

Exemple





Exemple




Matrice des corrélations

Projections





Projections



Seules les variables bien projetées peuvent être interprétées

Bilan ajustement des nuages



- Aide à interpréter les individus
- Représentation optimale des variables
- Visualisation de la matrice des corrélations

- 1 Contexte, données, problème
- 2 ACP : objectifs
- 3 Nuage des individus
- 4 Ajustement du nuage d'individus
- 5 Nuages des variables
- 6 Ajustement du nuage des variables
- 7 Déroulement, interprétation d'une ACP**

Sur un exemple

	Buts	Tirs	Jaune	Rouge	Possession	PassesReuss	DuelsAeriens	TirsContre	Tacles	Interception	Fautes	HorsJeu	TirsCadres	Dribbles	FautesSubies	Habillage
Manchester City	67	17.7	39	2	66.2	88.7	14.3	6.7	15.6	9.2	9.0	1.8	7.3	12.8	10.0	1
Manchester United	48	14.6	38	1	53.0	82.9	16.7	11.6	14.0	11.7	11.5	1.7	5.1	11.2	11.0	1
Chelsea	41	16.5	27	3	54.7	84.7	14.7	9.7	17.5	10.9	10.0	3.3	6.2	12.8	10.7	1
Liverpool	54	17.8	28	1	56.5	83.3	14.6	7.9	17.4	10.7	9.6	1.9	6.6	12.7	8.1	1
Tottenham	46	17.6	27	2	58.8	84.0	17.0	8.7	16.0	9.2	10.5	2.4	6.0	10.5	10.4	1
Arsenal	41	17.1	36	0	58.8	83.8	18.0	10.4	16.4	12.0	10.7	2.6	6.2	10.0	10.3	1
Burnley	19	9.7	41	0	44.3	70.3	25.1	16.2	14.6	10.9	9.4	3.3	3.2	6.2	10.7	1
Leicester	34	10.4	28	3	46.1	73.7	20.4	14.5	16.2	10.1	9.4	2.4	3.5	11.3	9.1	1
Crystal Palace	21	13.1	45	0	46.5	74.5	19.8	11.8	18.3	13.7	11.3	1.5	3.7	12.5	10.9	1
West Ham	29	9.8	52	2	46.9	75.8	20.4	15.2	16.0	12.4	9.9	2.4	3.7	10.9	12.7	1
Brighton	17	9.3	31	0	46.5	76.7	21.1	15.0	15.0	12.2	10.7	2.5	2.7	7.5	7.6	1
Newcastle United	21	12.2	34	2	43.7	73.0	23.7	13.1	16.9	10.6	11.0	1.6	4.1	7.8	9.8	1
Southampton	23	12.2	32	0	52.2	79.5	17.3	13.6	17.6	12.7	11.3	2.0	3.3	9.7	9.8	1
Watford	33	11.5	38	4	49.6	76.7	21.9	11.9	17.1	12.7	12.1	1.9	3.0	8.6	10.4	1
Everton	25	9.2	39	2	46.0	74.8	20.4	15.0	17.6	14.7	12.7	2.1	2.9	5.7	9.4	1

Répartition de l'inertie


Données centrées-réduites : inertie = nombre de variables

Comment se répartit-elle dans les différentes composantes principales ?


Axe	Valeur propre	% d'inertie	% cumulé d'inertie
1	5.84	38.9	38.9
2	1.97	13.1	52
3	1.83	12.2	64.1
4	0.99	6.6	70.7
5	0.92	6.1	76.8
6	0.85	5.7	82.5
...		...	
15	0.05	0.36	100

→ Choix du nombre de dimensions à interpréter


Premier plan factoriel



Premier plan factoriel



Deuxième plan factoriel



Contribution variables, individus à un axe

- Contribution d'une variable k à un axe s : $\frac{r(x_k, v_s)^2}{\sum_j r(x_j, v_s)^2}$

	Dim.1	Dim.2
Janv	6.047768	18.237917
Fevr	8.090417	9.665829
Mars	9.794799	1.069163
Avri	9.806233	1.822292
Mai	7.949651	9.899270
Juin	7.783119	10.953455
juil	7.390907	12.405755
Aout	8.427376	8.120089
Sept	9.901420	1.902383
Octo	10.026461	1.276365
Nove	8.524196	7.526504
Dece	6.257653	17.120979

Contribution variables, individus à un axe

- Contribution d'une variable k à un axe s : $\frac{r(x_k, v_s)^2}{\sum_j r(x_j, v_s)^2}$
- Contribution d'un individu i à un axe s : $\frac{F_{is}^2}{\sum_j F_{js}^2}$

	Dim.1	Dim.2
Janv	6.047768	18.237917
Fevr	8.090417	9.665829
Mars	9.794799	1.069163
Avri	9.806233	1.822292
Mai	7.949651	9.899270
Juin	7.783119	10.953455
juil	7.390907	12.405755
Aout	8.427376	8.120089
Sept	9.901420	1.902383
Octo	10.026461	1.276365
Nove	8.524196	7.526504
Dece	6.257653	17.120979

	Dim.1	Dim.2
Bordeaux	6.7759249	0.03498418
Brest	3.5789091	49.06878939
Clermont	2.0725832	1.02820712
Grenoble	1.6271372	8.34401167
Lille	12.3718247	1.03749158
Lyon	0.4850349	9.36488350
Marseille	16.2497301	2.01168233
Montpellier	11.9672370	0.55505413
Nantes	0.0550515	3.63802974
Nice	25.1063100	1.82452633
Paris	1.0731542	0.07158624
Rennes	1.4400400	8.17848800
Strasbourg	11.7277788	13.81902127
Toulouse	2.0972252	0.05426751
Vichy	3.3720591	0.96897702

Qualité de représentation : variables, individus

- Qualité de représentation d'une variable : $\cos^2$ entre la variable et sa projection

\$cos2	Dim.1	Dim.2	Dim.3	Dim.4	Dim.5
Janv	0.5794838	0.41517130	0.0004586977	2.599524e-03	9.903393e-04
Fevr	0.7752059	0.22003470	0.0011262232	1.357736e-04	2.847926e-05
Mars	0.9385160	0.02433862	0.0238242924	1.192842e-02	1.548185e-04
Avri	0.9396117	0.04148299	0.0148216612	2.923846e-03	2.238188e-04
Mai	0.7617180	0.22534881	0.0014866688	8.572653e-03	2.325094e-03

Qualité de représentation : variables, individus

- Qualité de représentation d'une variable : $\cos^2$ entre la variable et sa projection

\$cos2	Dim.1	Dim.2	Dim.3	Dim.4	Dim.5
Janv	0.5794838	0.41517130	0.0004586977	2.599524e-03	9.903393e-04
Fevr	0.7752059	0.22003470	0.0011262232	1.357736e-04	2.847926e-05
Mars	0.9385160	0.02433862	0.0238242924	1.192842e-02	1.548185e-04
Avri	0.9396117	0.04148299	0.0148216612	2.923846e-03	2.238188e-04
Mai	0.7617180	0.22534881	0.0014866688	8.572653e-03	2.325094e-03

- Qualité de représentation d'un individu : $\cos^2$ entre OM_i et OH_i sa projection

\$cos2	Dim.1	Dim.2	Dim.3	Dim.4	Dim.5
Bordeaux	0.94668773	0.001161224	5.050943e-02	2.093297e-05	5.974291e-06
Brest	0.23436246	0.763393814	6.013116e-04	7.509928e-05	4.350288e-04
Clermont	0.87988441	0.103705112	1.078243e-04	8.223376e-03	6.431728e-03
Grenoble	0.42894041	0.522580994	3.467164e-03	2.930774e-02	1.469480e-02

Qualité de représentation : variables, individus

- Qualité de représentation d'une variable : $\cos^2$ entre la variable et sa projection

\$cos2	Dim.1	Dim.2	Dim.3	Dim.4	Dim.5
Janv	0.5794838	0.41517130	0.0004586977	2.599524e-03	9.903393e-04
Fevr	0.7752059	0.22003470	0.0011262232	1.357736e-04	2.847926e-05
Mars	0.9385160	0.02433862	0.0238242924	1.192842e-02	1.548185e-04
Avri	0.9396117	0.04148299	0.0148216612	2.923846e-03	2.238188e-04
Mai	0.7617180	0.22534881	0.0014866688	8.572653e-03	2.325094e-03

- Qualité de représentation d'un individu : $\cos^2$ entre OM_i et OH_i sa projection

\$cos2	Dim.1	Dim.2	Dim.3	Dim.4	Dim.5
Bordeaux	0.94668773	0.001161224	5.050943e-02	2.093297e-05	5.974291e-06
Brest	0.23436246	0.763393814	6.013116e-04	7.509928e-05	4.350288e-04
Clermont	0.87988441	0.103705112	1.078243e-04	8.223376e-03	6.431728e-03
Grenoble	0.42894041	0.522580994	3.467164e-03	2.930774e-02	1.469480e-02

Seuls les éléments bien projetés peuvent être interprétés


Information supplémentaire

On dispose parfois d'informations supplémentaires sous la forme de nouvelles variables qui n'ont pas servi à faire l'ACP sur les données.

	Janv	Fevr	Mars	Avri	Mai	Juin	juil	Aout	Sept	Octo	Nove	Dece	Lati	Long	Moye	Ampl	Region
Bordeaux	5.6	6.6	10.3	12.8	15.8	19.3	20.9	21.0	18.6	13.8	9.1	6.2	44.50	-0.34	13.33	15.4	SO
Brest	6.1	5.8	7.8	9.2	11.6	14.4	15.6	16.0	14.7	12.0	9.0	7.0	48.24	-4.29	10.77	10.2	NO
Clermont	2.6	3.7	7.5	10.3	13.8	17.3	19.4	19.1	16.2	11.2	6.6	3.6	45.47	3.05	10.94	16.8	SE
Grenoble	1.5	3.2	7.7	10.6	14.5	17.8	20.1	19.5	16.7	11.4	6.5	2.3	45.10	5.43	10.98	18.6	SE
Lille	2.4	2.9	6.0	8.9	12.4	15.3	17.1	17.1	14.7	10.4	6.1	3.5	50.38	3.04	9.73	14.7	NE
Lyon	2.1	3.3	7.7	10.9	14.9	18.5	20.7	20.1	16.9	11.4	6.7	3.1	45.45	4.51	11.36	18.6	SE
Marseille	5.5	6.6	10.0	13.0	16.8	20.8	23.3	22.8	19.9	15.0	10.2	6.9	43.18	5.24	14.23	17.8	SE
Montpellier	5.6	6.7	9.9	12.8	16.2	20.1	22.7	22.3	19.3	14.6	10.0	6.5	43.36	3.53	13.89	17.1	SE
Nantes	5.0	5.3	8.4	10.8	13.9	17.2	18.8	18.6	16.4	12.2	8.2	5.5	47.13	-1.33	11.69	13.8	NO
Nice	7.5	8.5	10.8	13.3	16.7	20.1	22.7	22.5	20.3	16.0	11.5	8.2	43.42	7.15	14.84	15.2	SE
Paris	3.4	4.1	7.6	10.7	14.3	17.5	19.1	18.7	16.0	11.4	7.1	4.3	48.52	2.20	11.18	15.7	NE
Rennes	4.8	5.3	7.9	10.1	13.1	16.2	17.9	17.8	15.7	11.6	7.8	5.4	48.05	-1.41	11.13	13.1	NO
Strasbourg	0.4	1.5	5.6	9.8	14.0	17.2	19.0	18.3	15.1	9.5	4.9	1.3	48.35	7.45	9.72	18.6	NE
Toulouse	4.7	5.6	9.2	11.6	14.9	18.7	20.9	20.9	18.3	13.3	8.6	5.5	43.36	1.26	12.68	16.2	SO
Vichy	2.4	3.4	7.1	9.9	13.6	17.1	19.3	18.8	16.0	11.0	6.6	3.4	46.08	3.26	10.72	16.9	SE


Insertion variable quantitative

On projette les nouvelles variables sur le cercle des corrélations



Insertion variable qualitative

La corrélation n'a pas de sens pour une variable qualitative. On projette les modalités de cette variable au barycentre des individus de la modalité



Pratique de l'ACP

- 1 Choisir les variables actives
- 2 Choisir de réduire ou non les variables
- 3 Réaliser l'ACP
- 4 Choisir le nombre de dimensions à interpréter
- 5 Interpréter simultanément le graphe des individus et celui des variables
- 6 Utiliser les indicateurs pour enrichir l'interprétation
- 7 Revenir aux données brutes pour interpréter