

TD 1 : régression simple et multiple


1 Consommation de tabac en France

Le tableau ci-dessous rapporte le nombre de cigarettes vendues chaque année en France (de 1985 à 2014) ainsi que le prix relatif de vente de celles-ci (source INSEE). Le prix relatif du tabac (en €) correspond au prix nominal du tabac divisé par l'indice général des prix. (définition INSEE)

Année	Ventes cigarettes (en milliards) : Y	Prix relatif (€) : X
1985	94.75	72.1
1986	93.45	74.7
1987	94.10	76
1988	93	80.8
1989	94.93	81.3
1990	95.81	79.6
1991	97.10	78
1992	96.31	84.3
1993	93.62	98.3
1994	90.11	112.1
1995	88.34	119.6
1996	86.17	126.2
1997	82.98	134.6
1998	83.83	137.6
1999	83.67	143
2000	83.50	147.1
2001	84.45	152.1
2002	81.52	161.9
2003	70.59	181.3
2004	69.66	221.1
2005	69.53	218.4
2006	70.74	215.7
2007	69.71	218.1
2008	68.01	220.4
2009	69.81	223.2
2010	69.22	232
2011	68.64	240.3
2012	65.32	241.3
2013	60.35	264.1
2014	57.21	276.6

L'objectif de cet exercice est de savoir dans quelle mesure le prix de vente influence le nombre de cigarettes vendues. Dans un premier temps, on trace le nuage de points associé à ces données. Ce nuage de points est représenté dans la figure ci-dessous :

Données annuelles entre 1985 et 2014



1. D'après cette figure, le prix X semble-t-il influencer le nombre de cigarettes vendues Y ? Un modèle de régression linéaire pour expliquer Y à partir de X vous semble-t-il judicieux?

On vous donne les valeurs numériques suivantes :

$$\begin{cases} \bar{X} = 157.06 \\ \bar{Y} = 80.88 \\ \sum (X_i - \bar{X})(Y_i - \bar{Y}) = -23345.63 \\ \sigma_X^2 = \frac{\sum (X_i - \bar{X})^2}{30} = 4270.68 \\ \sigma_Y^2 = \frac{\sum (Y_i - \bar{Y})^2}{30} = 145.06 \end{cases}$$

2. Déterminez les coefficients a et b (estimations de α et de β) de la droite de régression obtenus par la méthode des moindres carrés, et tracez cette droite sur votre graphique.
3. En utilisant ce modèle, calculer le résidu associé à l'année 2000.
4. Soient $e_1, \dots, e_{30}$, les résidus du modèle obtenu ci-dessus. Sachant que $\sum_{i=1}^{30} e_i^2 = 97.96$, calculer le coefficient de détermination R^2 de ce modèle.
5. Rappeler les hypothèses classiques que l'on fait concernant la distribution des résidus.
6. Donner une estimation de la variance résiduelle associée à ce modèle.
7. Pour la régression simple, nous avons vu trois méthodes en cours pour tester si le modèle pouvait être considéré comme significatif :
 - (i) en testant l'hypothèse $\beta = 0$ contre l'hypothèse $\beta \neq 0$ (test de Student)
 - (ii) en calculant l'intervalle de confiance de β
 - (iii) par un test de significativité du modèle complet (test de Fisher)

Appliquer chacune de ces méthodes pour déterminer si X influence significativement Y .

8. En 2017, le prix relatif des cigarettes est passé à 288.3 €. Que prévoit le modèle concernant le nombre de cigarettes qui seront vendues en 2017? Calculer un intervalle de confiance pour cette prédiction.

9. A quel prix relatif devrait-on mettre le paquet de cigarettes pour que moins de 50 milliards de cigarettes soient vendus en une année ?

2 Résistance d'un matériau

Une entreprise fabrique un matériau en matière plastique qui est utilisé dans la fabrication de jouets. Le département de contrôle de qualité a effectué une étude qui a pour but d'établir dans quelle mesure la résistance à la rupture de cette matière plastique pouvait être affectée par l'épaisseur du matériau ainsi que la densité de ce matériau. Douze essais ont été effectués et les résultats sont présentés dans le tableau ci-dessous.

Essai numéro	Résistance à la rupture Y	Epaisseur X_1	Densité X_2
1	37.8	4	4
2	22.5	4	3.6
3	17.1	3	3.1
4	10.8	2	3.2
5	7.2	1	3
6	42.3	6	3.8
7	30.2	4	3.8
8	19.4	4	2.9
9	14.8	1	3.8
10	9.5	1	2.8
11	32.4	3	3.4
12	21.6	4	2.8

Diverses analyses ont été effectuées sur ordinateur et nous les résumons dans les tableaux suivants :

Régression de la résistance à la rupture Y en fonction de l'épaisseur X_1

Coefficients $\hat{\beta}_j$	Erreurs-types $s(\hat{\beta}_j)$	Source de variation	Somme des carrés	ddl
$\hat{\beta}_0 = 3,523$	$s(\hat{\beta}_1) = 1,279$	Régression X_1	980,64	1
$\hat{\beta}_1 = 6,036$		Résiduelle	440,03	10

Régression de la résistance à la rupture Y en fonction de la densité X_2

Coefficients $\hat{\beta}_j$	Erreurs-types $s(\hat{\beta}_j)$	Source de variation	Somme des carrés	ddl
$\hat{\beta}_0 = -36,373$	$s(\hat{\beta}_2) = 6,069$	Régression X_2	643,57	1
$\hat{\beta}_2 = 17,464$		Résiduelle	777,10	10

Régression de la résistance à la rupture Y en fonction de l'épaisseur X_1 et de la densité X_2

Coefficients $\hat{\beta}_j$	Erreurs-types $s(\hat{\beta}_j)$	Source de variation	Somme des carrés	ddl
$\hat{\beta}_0 = -30,081$	$s(\hat{\beta}_1) = 1,014$ $s(\hat{\beta}_2) = 3,621$	Régression (X_1, X_2)	1204,86	2
$\hat{\beta}_1 = 4,905$		Résiduelle	215,81	9
$\hat{\beta}_2 = 11,072$				

1. Calculer le coefficient de détermination pour chacun des 3 modèles de régression.
2. Compléter le tableau suivant :

	CM_r	$\hat{\sigma}$
Régression due à X_1		
Régression due à X_2		
Régression due à (X_1, X_2)		

3. Calculer le carré moyen (CM_m) du modèle expliquant Y en fonction de (X_1, X_2) .
4. Tester au seuil de signification 95% si l'une des deux variables explicatives **au moins** joue bien un rôle dans l'explication de Y (Test de Fisher du modèle complet). Conclusion ?
5. Peut-on dire, d'après les résultats du modèle 1, que X_1 influence Y de manière significative ?
6. Tester maintenant si l'ajout de la variable X_2 (quand X_1 est déjà présent) apporte une information significative pour expliquer Y . Conclusion ?
7. L'entreprise voudrait estimer la résistance d'un matériau d'épaisseur 3.5 et de densité 3.9. Comment pouvez-vous l'aider à faire cette estimation ?