

Devoir d'analyse de données avec R

On considère le data frame nommé **dataresto.csv** dont les colonnes sont séparées par une virgule.

1. Importer les données dans un data frame intitulé **resto**.
2. Ecrire un code permettant d'obtenir la structure générale des variables de **resto**. En déduire la taille de l'échantillon, le nombre de variables du data frame et les types des variables.

3. On s'intéresse à la variable **size** du data frame **resto**.

- (3.a) Donner le résumé numérique de la variable **size**.
- (3.b) Renommer les modalités de la variable **size** comme suit : les modalités 1 et 2 deviennent *low.size*, les modalités 3 et 4 deviennent *average.size* et les modalités 5 et 6 deviennent *high.size*.
- (3.c) Transformer la variable **size** en facteur.
- (3.d) Déterminer le tableau des effectifs de la variable **size**.
- (3.e) Représenter graphiquement la variable **size** par un diagramme en barres.

4. On s'intéresse à la variable **smoker**.

- (4.a) Une étude recommande d'organiser des campagnes de sensibilisation si la proportion de fumeurs dépasse 30%. Faut-il organiser des campagnes de sensibilisation pour cette population ?
- (4.b) Créer un data frame nommé **restoF** contenant les femelles et un data frame nommé **restoM** contenant les mâles.
- (4.c) Déterminer le tableau des effectifs puis des fréquences de la variable **smoker** dans le data frame **restoF**.
- (4.d) Déterminer le tableau des effectifs puis des fréquences de la variable **smoker** dans le data frame **restoM**.
- (4.e) Effectuer le test d'égalité des proportions de fumeurs chez les femelles et les mâles.

5. On s'intéresse aux variables **tip** et **smoker**.

- (5.a) Déterminer le tableau des fréquences de la variable **tip**.
- (5.b) Déterminer le tableau des distributions conditionnelles de la variable **tip** sachant la variable **smoker**.
- (5.c) Les variables **tip** et **smoker** sont-elles indépendantes ? Justifier votre réponse.
- (5.d) Construire les diagrammes en boîte à moustaches de la variable **tip** en fonction des modalités de la variable **smoker**.
- (5.e) Calculer le rapport de corrélation de **tip** sachant **smoker**. Conclure.

6. On s'intéresse aux variables **day** et **time**.

- (6.a) Construire le tableau de contingence des deux variables avec les modalités de la variable **time** en lignes.
- (6.b) Construire le diagramme en barres de la variable **day** en fonction de la variable **time**. Que suggère le graphique ?
- (6.c) Effectuer le test d'indépendance des deux variables. Conclure.