

■ Définition

- Données massives
 - ✓ 2,5 trillions d'octets de données générées par jour
 - ✓ 90% des données mondiales créées ces 2 dernières années
 - ✓ 90% des données générées sont non structurées
 - ✓ Provenant de diverses sources
 - Capteurs utilisés pour collecter les informations climatiques
 - Messages sur les médias sociaux
 - Images numériques et vidéos publiées en ligne
 - Enregistrements transactionnels d'achat en ligne
 - Signaux GPS de téléphones mobiles
 - ...



Big Data & NoSQL

■ Sources

- Multiples:
 - ✓ sites, bases de données, téléphones, serveurs:
 - Détecter les sentiments et réactions des clients
 - Détecter les conditions critiques ou potentiellement mortelles dans les hôpitaux , et à temps pour intervenir
 - Prédire des modèles météorologiques pour planifier l’usage optimal des éoliennes
 - Prendre des décisions risquées basées sur des données transactionnelles en temps réel
 - Identifier les criminels et les menaces à partir de vidéos, sons et flux de données
 - Étudier les réactions des étudiants pendant un cour, prédire ceux qui vont réussir, d’après les statistiques et modèles réunis au long des années (domaine Big Data in Education)

■ intérêts

- Intérêts multiples
 - ✓ 34% des chefs d'entreprise prennent fréquemment des décisions basées sur des informations en lesquelles ils n'ont pas confiance, ou qu'ils n'ont pas
 - ✓ 50% des chefs d'entreprise disent qu'ils n'ont pas accès aux informations dont ils ont besoin pour faire leur travaux
 - ✓ 83% des DSI (Directeurs des SI) planifient d'utiliser « L'informatique décisionnelle et analytique »
 - ✓ 60% des PDG ont besoin d'améliorer la capture et la compréhension des informations pour prendre des décisions plus rapidement



Big Data & NoSQL


■ Challenges

- Réunir un grand volume de données variées pour trouver de nouvelles idées
- Capturer des données créées rapidement
- Sauvegarder toutes ces données
- Traiter ces données et les utiliser

Big Data & NoSQL

■ Caractéristiques

- Extraction d'informations et prise de décisions à partir de données, caractérisées par les 5V:
 - ✓ Volume (Volume)
 - ✓ Variété (Variety)
 - ✓ Vitesse (Velocity)
 - ✓ Véracité (Veracity)
 - ✓ Valeur (Value)



■ Caractéristiques

- Volume
 - ✓ Prix de stockage de données a beaucoup diminué
 - De \$100 000 /Go en 1980
 - À \$0,10/Go en 2013
 - ✓ Lieux de stockage fiables (SAN) ou réseaux peuvent être couteux
 - Choisir de ne stocker que certaines données, jugées sensibles
 - Perte de données, pouvant être très utiles, comme les logs
 - ✓ Comment déterminer les données qui méritent d'être stockées?
 - ✓ Aucune donnée n'est inutile
 - Certaines n'ont juste pas encore servi

■ Caractéristiques

- Variété
 - ✓ Pour un stockage dans des bases de données ou dans des entrepôts de données, les données doivent respecter un format prédéfini.
 - ✓ La plupart des données existantes sont non structurées ou semi-structurées
 - Données sous plusieurs formats et types
 - On veut tout stocker
 - ✓ Certaines données peuvent paraître obsolètes, mais sont utiles pour certaines décisions

■ Caractéristiques

- Vitesse
 - ✓ Rapidité d'arrivée des données
 - ✓ Vitesse de traitement
 - ✓ Les données doivent être stockées à l'arrivée, parfois même des Teraoctets par jour
 - Sinon, risque de perte d'informations
 - ✓ Exemple
 - Il ne suffit pas de savoir quel article un client a acheté ou réservé
 - Si l'on sait que vous avez passé plus de 5mn à consulter un article dans une boutique d'achat en ligne, il est possible de vous envoyer un email dès que cet article est soldé

■ Caractéristiques

- VÉRACITÉ
 - ✓ C'est la fiabilité des données. Avec l'augmentation de la quantité, la qualité et précision se perdent (abréviations, typos, déformations, source peu fiable...)
 - ✓ Les solutions Big Data doivent remédier à cela en se référant au volume des données existantes
 - ✓ Nécessité d'une très grande rigueur dans l'organisation de la collecte et le recoupement, croisement, enrichissement des données.

■ Caractéristiques

- Valeur
 - ✓ Le V le plus important
 - ✓ Il faut transformer toutes les données en valeurs exploitables: les données sans valeur sont inutiles
 - ✓ Atteindre des objectifs stratégiques de création de valeur pour les clients et pour l'entreprise dans tous les domaines d'activité

■ Approche traditionnelle

- Les besoins métier guident la conception de la solution
 1. Le responsable métier définit les besoins : Quelles questions doit-on poser?
 2. IT conçoit une solution avec un ensemble de structures et Fonctionnalités
 3. Le responsable métier exécute les requêtes pour répondre aux questions – encore et encore
 4. De nouvelles exigences nécessitent une nouvelle conception et construction

■ Approche traditionnelle

- Est appropriée pour :
 - ✓ Des données structurées
 - ✓ Opérations et processus répétitifs
 - ✓ Sources relativement stables
 - ✓ Besoins bien compris et bien cadrés

■ Approche Big Data

- Les sources d'information guident la découverte créative
 1. Le responsable métier et IT identifient les sources de données disponibles
 2. IT fournit une plateforme qui permet une exploration créative de toutes les données disponibles
 3. Le responsable métier détermine les questions à poser en explorant les données et relations entre elles
 4. De nouvelles idées conduisent à l'intégration de technologies traditionnelles



Big Data & NoSQL

■ Approche classique vs Approche Big Data

- La question n'est pas :
 - ✓ Dois-je choisir entre l'approche classique et l'approche Big Data?
- Mais plutôt :
 - ✓ Comment les faire fonctionner ensemble?

Big Data & NoSQL

■ Approche classique vs Approche Big Data

Approche Traditionnelle

Analyse Structurée et Répétée

Responsables Métier

Déterminent quelles questions poser



Responsables IT

Structurent les données pour répondre à ces questions



Approche Big Data

Analyse Itérative et Exploratoire

Responsables IT

Fournissent une plateforme pour permettre la découverte créative



Responsables Métier

Explorent la plateforme pour déterminer quelles questions poser



■ Les outils

- Le Big Data nécessite :
 - ✓ Des bases de données NoSQL
 - Pour le stockage de données massives
 - Non structurées ou semi-structurées
 - Les SGBDR ne conviennent pas
 - ✓ Des systèmes de traitement de données réparties (distribuées)
 - Hadoop (High Availability Distributed Object Oriented Platform)
 - Implémentation de l'algorithme Map/Reduce
 - Avec des mécanismes Yarn ou Spark

■ Bases de données NoSQL

- Origine
 - ✓ 1998 : naissance du terme
 - NoSQL par Shashank Tiwari
 - ✓ 2009 : meetup de San Francisco
 - 100 participants des principaux acteurs
 - ✓ 2010 : Premières bases NoSQL
 - ✓ Première signification : Pas de SQL
 - Puis : Not Only SQL
 - ✓ Autres noms :
 - Big Data
 - NotRelational

Big Data & NoSQL

■ Bases de données NoSQL

- Les utilisateurs



Big Data & NoSQL

■ Bases de données NoSQL

- Pourquoi faire?
 - ✓ Gérer des volumes de données énormes
 - Plusieurs téra octets
 - ✓ Des performances en lectures/écritures
 - Centaines de milliers de lectures/secones
 - Centaines de milliers d'écritures/secones
 - ✓ Distribuer ses données
 - Répartition multisites
 - Éviter les Single Point Of Failure
 - Load balancing
 - ✓ S'affranchir des schémas rigides

signe	préfixe	facteur
K	Kilo	10^3
M	Méga	10^6
G	Giga	10^9
T	Téra	10^{12}
P	Péta	10^{15}
E	Exa	10^{18}
Z	Zetta	10^{21}

■ Bases de données NoSQL

- Cas pratiques
 - ✓ Gérer des logs
 - ✓ Stocker des messages utilisateurs
 - ✓ Stocker des données de crawling
 - Exploration d'un site Web par le robot d'un moteur de recherche
 - ✓ Remplacer les DataWarehouses
 - Business Intelligence (entrepôts de données)
 - ✓ Stocker des données hétérogènes

■ Bases de données NoSQL

- Les grands principes
 - ✓ Pas de jointures
 - ✓ Des moteurs simples
 - ✓ Des Apis propres à chaque moteur
 - ✓ Des données distribuées
 - ✓ Structures flexibles
 - ✓ Duplication de données

■ Bases de données NoSQL


- Les types de bases de données NoSQL
 - ✓ Clefs/Valeurs
 - ✓ Documents
 - ✓ Colonnes
 - ✓ Graphes

Big Data & NoSQL

■ Bases de données NoSQL

- Les types de bases de données NoSQL

- ✓ Clefs/Valeurs



- Simple
 - Rapide
 - Moteur ne connaît pas le contenu




Big Data & NoSQL

■ Bases de données NoSQL

- Les types de bases de données NoSQL

- ✓ Documents

- Données hiérarchiques
- Plusieurs types de documents : XML, JSON, etc.
- Indexation possible du contenu




Big Data & NoSQL

■ Bases de données NoSQL

- Les types de bases de données NoSQL

- ✓ Colonnes

- Chaque ligne possède des colonnes différentes
- Très flexibles




Big Data & NoSQL

■ Bases de données NoSQL

- Les types de bases de données NoSQL

- ✓ Graphes


- Liens complexes et flexibles entre les données
- Modélisation proche de la réalité



Big Data & NoSQL

■ Traitement des données

- L'algorithme Map/Reduce en théorie
 - ✓ Calcul distribué sur des données énormes (> 1Tb)
 - ✓ Découpage du problème en sous-problèmes (map)
 - ✓ Agrégation des résultats (reduce)
- Map/Reduce en image



■ Traitement des données

- standardisation
 - ✓ Chaque moteur possède son langage de requête
 - ✓ Certains réintègrent un SQL allégé
 - ✓ Frameworks de standardisation :
 - En Java : Spring Data, Hibernate OGM
 - En DotNet : Linq
 - ✓ Encore du chemin à parcourir

■ Traitement des données

- L'avenir : multi-BDD
 - ✓ Chaque solution possède ses avantages et inconvénients
 - ✓ Utiliser le bon outil pour le bon problème
 - ✓ Pas de remplacement des SGBDR mais un complément
 - ✓ Au final les applications auront plusieurs bases