

Théorie des langages

Olivier Ridoux

Expressions régulières

Plan

- Expressions régulières
regular expressions (RE, regexp)
- Les outils
- Expressivité des RE

Expressions régulières

Motivation

- Exprimer un langage en termes de langages « plus simples »
- Décrire un nouveau langage en combinant des langages existants
- Décrire un langage en utilisant les **opérations** sur les langages

Expressions régulières (1)

- Def. Langage des RE

a est une RE si $a \in \Sigma$

ϵ est une RE

$\emptyset$ est une RE

r^* est une RE, si r est une RE

$r_1 \mid r_2$ est une RE, si r_1 et r_2 sont des RE

$r_1 \bullet r_2$ est une RE, si r_1 et r_2 sont des RE

À retenir absolument !

Expressions régulières (2)

- RE est un **méta-langage**

- Def. $\mathcal{L} : \text{RE} \rightarrow \mathcal{P}(\Sigma^*)$

$$\mathcal{L}(a) = \{a\}$$

$$\mathcal{L}(\varepsilon) = \{\varepsilon\}$$

$$\mathcal{L}(\emptyset) = \emptyset$$

(à suivre)

À retenir absolument !

si $a \in \Sigma$

Expressions régulières (3)

- Def. (suite) $\mathcal{L} : \text{RE} \rightarrow \mathcal{P}(\Sigma^*)$

...

$$\mathcal{L}(r^*) = \mathcal{L}(r)^*$$

si r est une RE

$$\mathcal{L}(r_1 \mid r_2) = \mathcal{L}(r_1) \cup \mathcal{L}(r_2)$$

si r_1 et r_2 sont des RE

$$\mathcal{L}(r_1 \cdot r_2) = \mathcal{L}(r_1) \cdot \mathcal{L}(r_2)$$

si r_1 et r_2 sont des RE



Notation

- Expression ensembliste

langage + ε n'a pas de sens !

- Expression régulière

$r \mid \varepsilon$ a du sens !

...et signifie **$\mathcal{L}(r) + \{\varepsilon\}$**

Expressions régulières (4)

- Def. **Langages rationnels**



À retenir absolument !

on dit qu'un langage est rationnel si
il est la sémantique d'une expression régulière

- description finie : expression régulière **re**
- langage : $\mathcal{L}(\text{re})$

possiblement infini : $\mathbf{r}^*$

Variations (1)

- Variations **anodines**

$$[abc] = (a \mid b \mid c)$$

$$[a-z] = (a \mid b \mid \dots \mid z)$$

r ou $r\$$ (recherche de motifs)

$$r^{0|1} = r? = [r] = (r \mid \varepsilon)$$

$$r^n = \underbrace{r \bullet r \bullet \dots \bullet r}_{(n \text{ fois})}$$

Variations (2)

- Variation **moins anodine**

$$r_1 - r_2$$
$$\text{tq } \mathcal{L}(r_1 - r_2) = \mathcal{L}(r_1) - \mathcal{L}(r_2)$$

– ne change pas la notion de langage rationnel

– améliore grandement la **facilité** d'expression

$$\text{la RE } r \text{ tq } \mathcal{L}(r) = \mathcal{L}(r_1) - \mathcal{L}(r_2)$$

ne ressemble ni à r_1 ni à r_2

les heures de 0 à 23 : $[0-9] | ([1-2] \bullet [0-9] - (2 \bullet [4-9]))$

Exemples (1)

- Langage des notations d'entiers en base 10

0, 1, 2, ..., 10, 113, 2012, ..., mais pas 00, 01, 02, ...

$$(0|1|2|3|4|5|6|7|8|9)^+$$
$$(:\text{digit}:)^+$$
$$(:\text{digit}:-0) \bullet (: \text{digit}:)^*$$
$$(0 \mid (:\text{digit}:-0) \bullet (: \text{digit}:)^*)$$

symbole générique

Exemples (2)

- Langage des notations scientifiques

0, 1, 1.328, 1E58, 1.328E58, mais pas 1., 1.E2, 0.1

$(0 \mid (:digit:-0) \bullet (\epsilon \mid '.' \bullet (:digit:)^+) \bullet (\epsilon \mid 'E' \bullet (:digit:)^+))$

$(0 \mid (:digit:-0) \bullet ['.' \bullet (:digit:)^+] \bullet ['E' \bullet (:digit:)^+])$

distinguer langage et méta-langage



'.' et **•** (en fait, **'.'** et **.**)

Exemples (3)

- Il est souvent avantageux de donner des noms aux langages

dgtnz = (:digit:-0)

digit non zero

dgtsne = (:digit:)+

digits non empty

scinot

notation scientifique

= (0 | **dgtnz** • [' . ' • **dgtsne**] • [' E ' • **dgtsne**])

Exemples (4)

- Commentaires à la C, Java, ...

`/* bla bla */ ... /* toto */`

`'/' • '*' • (:char:)* • '*' • '/'`



`*/ ∈ SEM( (:char:)* )`

`/* bla bla */ bla */`

Problème récurrent avec les notations « bornées »
expression régulière compliquée, ou bien ...
...consommation **gourmande** (*eager*) ou pas

Outils RE

Familles d'outils RE

- Outils script, à la shell UNIX
 - **grep, sed, AWK**
- Langages de programmation
 - **Perl**, etc
- Générateur d'analyseurs syntaxiques
 - **Lex, ANTLR, regexp Java, Python, ...**
- Bases de données
 - **REGEXP**

Les outils UNIX

- `grep RE source`
 - recherche dans source des **lignes** qui contiennent une instance de RE
- `sed -e s/RE/substitution/`
 - recherche RE et effectue une **substitution**
- `awk /RE/ action`
 - recherche RE et effectue une **action**

Les outils d'analyse syntaxique (1)

exemple synthétique

```
lexer {  
  RE1 token1 ,  
  RE2 token2 ,  
  ...  
  alpha+ ident ,  
  ...  
  REn tokenn  
}
```

```
token t = lexer.first(s) ; list <token> lt = lexer.split(s)
```

token = symbole
RE_i peut utiliser token_j si j < i

Les outils d'analyse syntaxique (2)

- regex Java, Scala, ...

exemple synthétique

```
regex re = "[a-zA-Z]\w*"  
pos p = re.first(s)
```

Les outils base de données

- SELECT ...

FROM ...

WHERE a **REGEXP RE**

Expressivité des RE

Théorème (1961)

- Th. **Lemme étoile**, ou **de pompage**

Si $\mathcal{L}$ est rationnel


alors $\exists N_{\mathcal{L}}. \forall m \in \mathcal{L}. [$

si $\text{longueur}(m) \geq N_{\mathcal{L}}$

alors $\exists x, y, z. [0 < \text{longueur}(x \bullet y) \leq N_{\mathcal{L}}$

$\wedge m = x \bullet y \bullet z$

$\wedge x \bullet y^n \bullet z \in \mathcal{L}]]$



- Sert à montrer qu'un $\mathcal{L}$ n'est pas rationnel

$$\neg \textcircled{B} \Rightarrow \neg \textcircled{A}$$


En image - Lemme de pompage

• Si $m =$



alors

$m =$



tel que



En français - Lemme de pompage

- Si un mot d'un langage rationnel est **suffisamment** long ($> N_{\mathcal{L}}$),

...il a forcément été produit par la **répétition** d'un motif qui vient **suffisamment** tôt ($< N_{\mathcal{L}}$)

- Un mot **arbitrairement** long ($> N_{\mathcal{L}}$) doit utiliser la **répétition** (*)

Application - Lemme de pompage

- Langage des **palindromes**

121, kayak, laval, ressasser

$$\mathcal{L} = \{ m \mid m_i = m_{\text{longueur}(m)-i+1} \} \text{ et } \mathcal{L} = \text{SEM}(\text{re})$$

- $M = \text{abcdefghijk} \mid \text{mlkjihgfedcba}$

$N_{\mathcal{L}}$

alors $\text{abcdefgh} \text{iiiiiiij} \text{kl} \text{mlkjihgfedcba} \in \mathcal{L}$

Contradiction !

Attention - palindrome !

- Langage des nombres

$\ni$ le langage des palindromes

121 $\in \mathcal{L}([0-9]^*)$, mais aussi **2012**

- Langage des identificateurs

$\ni$ le langage des palindromes

kayak $\in \mathcal{L}([a-z]^*)$, mais aussi **canoe**

👉 **un langage rationnel peut contenir
un langage non rationnel**

Application - Lemme de pompage

- Langage des $a^n b^n$ $((('n'))^n)$ (pushⁿ popⁿ)
 $\mathcal{L} = \{ a^n b^n \mid n \geq 0 \}$ et $\mathcal{L} = \text{SEM}(\text{re})$

- $M = \text{aaa}$ **aaa****|**aaabbbbbbbbbbb

$N_{\mathcal{L}}$

alors **aaa****aaa****aaa**aaabbbbbbbbbbb $\in \mathcal{L}$

Contradiction !

Limite de l'expressivité des RE (1)

- Tous les langages ne sont pas rationnels
- Les RE n'engendrent
que les langages rationnels

**⇒ Les RE ne peuvent pas engendrer
tous les langages**

Limite de l'expressivité des RE (2)

- V^* est infini dénombrable
 $\Rightarrow \mathcal{P}(V^*)$ n'est pas dénombrable

- RE est dénombrable

$\Rightarrow$ Il y a moins de RE que de langages

$\Rightarrow$ Les RE ne peuvent pas engendrer
tous les langages

Conclusion (1)

- Regex = description qui emploie les opérations sur les langages pour construire des gros langages avec des petits

**Construire un langage complexe
avec des langages plus simples**

Conclusion (2)

- Une notation qui fait partie du langage informaticien

* ou + = répétition

| = alternative

• = produit m
(concaténation)

Conclusion (3)

- RE décrivent bien certains langages...

...mais **pas tous**

...et **pas du tout leur reconnaissance**

$(a|b)^* \bullet (c|d)^* \bullet (a|b)^* \dots$

« abba... »

par où commencer ?