

Répondre de façon **concise mais précise** aux questions suivantes en utilisant les cadres. **Utiliser les notations du cours et du TD.** Aucun document n'est autorisé, hormis un aide-mémoire manuscrit de format A4 recto seul constitué par chaque étudiant. Ce sujet comporte 2 pages. **Commencer** par remplir nom, prénom et numéro étudiant.

**Numéro :****Nom :****Prénom :**

Les consignes générales avaient beau dire de « Commencer par remplir nom, prénom et numéro étudiant », certains se sont mis dans la situation de quémander du temps pour faire à la fin ce qu'il fallait faire au début.

**1. Répondre aux questions suivantes en justifiant brièvement la réponse.**

- **Soit  $\mathcal{D}$  un ensemble vide. Combien d'éléments  $\mathcal{P}(\mathcal{D})$  contient-il ?**

1 élément :  $\mathcal{D}$  lui-même, soit  $\emptyset$ .

Se rappeler que dans l'ensemble des parties d'un ensemble il y a toujours l'ensemble lui-même et l'ensemble vide. Cela fait 2 raisons pour que  $\mathcal{D}$  soit un élément de  $\mathcal{P}(\mathcal{D})$ . Mais comme il est lui-même vide, il n'y a pas d'autre partie.

Et surtout pas  $\varepsilon$  ! Le mot vide,  $\varepsilon$ , l'ensemble vide,  $\{\}$  ou  $\emptyset$ , et le singleton du mot vide,  $\{\varepsilon\}$ , sont 3 choses différentes. Ce n'est pas comme si on n'en avait jamais parlé.

- **Soit  $\mathcal{E}$  un ensemble infini. Combien  $\mathcal{D} \times \mathcal{E}$  comporte-t-il d'éléments ?**

$\mathcal{D} \times \mathcal{E}$  est l'ensemble des couples  $(d, e)$  tels que  $d \in \mathcal{D}$  et  $e \in \mathcal{E}$ . Mais  $\mathcal{D}$  est vide, il n'y a donc pas de  $d$ , donc pas de  $(d, e)$ , donc  $\mathcal{D} \times \mathcal{E}$  comporte 0 éléments.  $\mathcal{D} \times \mathcal{E}$  est vide.

C'est la même situation que  $\emptyset \bullet \mathcal{L} = \emptyset$  vue en cours.

- **Soit  $\mathcal{F}$  un ensemble fini de taille  $n$ . Combien existe-t-il de séquences d'éléments de  $\mathcal{F}$  qui soient de longueur  $m$  ? Combien existe-t-il de séquences d'éléments de  $\mathcal{F}$  qui soient de longueur inférieure ou égale à  $m$  ?**

$\mathcal{F}$  est donc un vocabulaire de taille  $n$ , et on cherche le nombre de mots de longueur  $m$  qu'on peut former sur  $\mathcal{F}$ . C'est exactement  $n^m$ . En effet, on a le choix entre  $n$  éléments de  $\mathcal{F}$  pour la première position de la séquence, mais aussi pour la deuxième, mais aussi pour la troisième, etc. Soit  $n \times n \times \dots \times n$ ,  $m$  fois.

Et il y a donc  $\sum_{i \in [0, m]} n^i$  mots de longueur inférieure ou égale à  $m$ , soit  $(n^{m+1} - 1) / (n - 1)$ .

## 2. Répondez brièvement aux questions suivantes :

- **Un voltmètre lit en continu la tension d'alimentation d'un appareil et coupe le circuit en cas de surtension. Peut-on le considérer comme un automate fini ?**

Non, car ce que lit un automate fini ce sont les lettres en nombre fini d'un vocabulaire. Des lettres bien distinguables les unes des autres, et pas les valeurs de la mesure d'un phénomène continu.

- **Soit  $f$  une fonction de  $\mathbb{N}$  dans  $\{0, 1\}$ . On la code dans un mot tel que la  $i$ -ème position du mot est  $f(i)$ . Qu'en pensez-vous ?**

L'ensemble  $\{0, 1\}$  forme bien un vocabulaire fini de lettres bien distinguables les unes des autres, mais la séquence qui encode la fonction  $f$  est infinie puisqu'elle court sur tout  $\mathbb{N}$ . Elle ne forme donc pas un mot au sens du module TL de L3 MIAGE où tous les mots sont finis.

**Soit l'alphabet  $\Sigma = \{ -, A, B \}$ . Soit  $\mathcal{L}_0$  le langage des mots sur  $\Sigma$  qui commencent par un '-', et où un A ne peut pas suivre un B.**

## 3. Proposez une expression régulière standard (du type de celles qui sont définies dans le cours) qui décrit le langage $\mathcal{L}_0$ .

$$RE_{\mathcal{L}_0} = '-' \cdot A^* \cdot B^* \cdot ('-^+ \cdot A^* \cdot B^*)^*$$

Soit un '-' suivi éventuellement d'une séquence de A puis d'une séquence de B, puis un certain nombre de fois d'au moins un '-', suivi éventuellement de ... Comme les B ne peuvent pas être suivis d'un A, ils sont forcément soit suivis d'un '-' soit en dernière position du mot. Des tas d'autres variantes sont possibles.

Rien ne dit qu'il y a obligatoirement des A ou des B. Si un mot commence par plusieurs '-', le premier vient du début de  $RE_{\mathcal{L}_0}$ , et les autres viennent de  $'-^+$ .


## 4. Proposez une expression régulière avec soustraction ensembliste qui décrit le langage $\mathcal{L}_0$ .

$$RE_{\mathcal{L}_0} = '-^* \cdot (A \mid B \mid '-')^* - .^* \cdot B \cdot A \cdot .^*$$

Autrement dit, un '-' suivi de A, B et '-' en vrac, sauf les mots qui contiennent un B suivi d'un A.


Dans les questions suivantes, ne donner que les représentations graphiques des automates.

5. Proposer un automate fini qui reconnaît  $\mathcal{L}_0$ .




Soit l'alphabet  $\Sigma = \{ -, A \}$ . Soit  $\mathcal{L}_1$  le langage des mots sur  $\Sigma$  qui commencent par un '-', et où les '-' sont toujours isolés, et  $\mathcal{L}_2$  le langage des mots sur  $\Sigma$  qui commencent par un '-', et où les '-' viennent toujours par 2 exactement (ni 1, ni 3, ni 4, etc.).

6. Proposer un automate fini qui reconnaît  $\mathcal{L}_1$  est un autre qui reconnaît  $\mathcal{L}_2$ .



7. Donner le principe de la construction d'un automate non déterministe qui reconnaît  $\mathcal{L}_1 \cup \mathcal{L}_2$ .

Il suffit de construire un automate dont l'état initial conduit dans l'un où l'autre des automates qui reconnaissent  $\mathcal{L}_1$  ou  $\mathcal{L}_2$ .



Évidemment, il ne faut se brancher naïvement sur les états initiaux de ces automates car sinon on lirait le '-' une fois de trop ! Il faut juste effectuer depuis l'état initial du nouvel automate les transitions qu'on pouvait effectuer depuis les anciens automates.

Évidemment, le nouvel automate n'est pas déterministe, et c'est pourquoi il y a une question 8 !

Attention ! le langage  $\mathcal{L}_1 \cup \mathcal{L}_2$  est celui qui fait l'union des mots de  $\mathcal{L}_1$  et de ceux de  $\mathcal{L}_2$ . Ce n'est pas le langage qui mélange les règles de formation des mots de  $\mathcal{L}_1$  et de ceux de  $\mathcal{L}_2$  ; du genre avoir toujours 1 ou 2 '-'. Quand dans le nouvel automate on est parti dans l'état 3, on reste dans l'automate de  $\mathcal{L}_1$  ; symétriquement, quand on est parti dans 4, on reste dans l'automate de  $\mathcal{L}_2$ . Autant faire ce qui est demandé ici est facile, autant faire ce qui n'est pas demandé est difficile !

#### 8. Déterminiser l'automate réponse de la question 7.

| Q <sub>det</sub> | -                                                    | A                                   |
|------------------|------------------------------------------------------|-------------------------------------|
| {0}              | <b>{3, 4}</b> (dans F <sub>det</sub> , à cause de 3) |                                     |
| {3, 4}           | <b>{6}</b> (dans F <sub>det</sub> )                  | <b>{5}</b> (dans F <sub>det</sub> ) |
| {6}              |                                                      | <b>{8}</b> (dans F <sub>det</sub> ) |
| {5}              | <b>{3}</b> (dans F <sub>det</sub> )                  | <b>{5}</b> (dans F <sub>det</sub> ) |
| {8}              | <b>{4}</b>                                           | <b>{8}</b> (déjà vu)                |
| {3}              |                                                      | <b>{5}</b> (déjà vu)                |
| {4}              | <b>{6}</b> (déjà vu)                                 |                                     |

Au total, les états 3 et 4 sont fusionnés dans un nouvel état {3, 4} pour les transitions qui viennent de l'état initial {0}, mais ils subsistent séparément pour les transitions sur '-' qui viennent de {5} et {8} respectivement. Si ces transitions avaient conduit vers {3, 4} le nouvel automate aurait accepté des mots qui commencent comme dans  $\mathcal{L}_1$  et finissent comme dans  $\mathcal{L}_2$ , et toutes les combinaisons possibles des 2. Lire la remarque finale de la question précédente. Appliqué correctement, l'algorithme de déterminisation évite cela sans qu'on ait à y penser.

Répondre de façon **concise mais précise** aux questions suivantes en utilisant les cadres. **Utiliser les notations du TP**. Aucun document n'est autorisé, hormis un aide-mémoire manuscrit de format A4 recto seul constitué par chaque étudiant. Ce sujet comporte 2 pages. **Commencer** par remplir le cadre nom, prénom et numéro étudiant.

**Toutes les questions attendent une réponse dans le contexte du package `regex`.**

**1. Répondre aux 3 questions suivantes :**

- **Comment est représenté  $\Sigma$  ?**

$\Sigma$  n'est pas représenté explicitement.

$\Sigma$  est par défaut l'ensemble de tous les caractères, mais l'ensemble des notations d'intervalles (`[ ... ]`) et de catégories de caractères (`\d`, `\w`, ...) permet de préciser les caractères à utiliser vraiment.

- **Comment est représentée la concaténation ?**

La concaténation n'est pas représentée par un symbole particulier (comme `•` en cours ou `+` en Java) mais par simple juxtaposition.

On a vu en cours que la concaténation était souvent laissée implicite (tout comme le produit de langage, et les produits en algèbre classique), et c'est le cas pour les `regex`.

En `regex`, le point (`.`) a un tout autre sens. Lequel ?

- **À quoi sert le point d'interrogation (`?`) ?**

Le point d'interrogation sert à dénoter ce qui est optionnel, soit l'alternative avec le mot vide :  $(regex)? = ((regex) | \epsilon)$ .

**2. Le package `regex` offre deux formes de soustraction ensembliste. Décrivez-les.**

- Une première forme concerne les intervalles de lettres. Par exemple, la notation `[a-z&[^m-p]]` représente l'intervalle `[a-z]` privé des éléments de l'intervalle `[m-p]`.

Noter que hors de ce contexte `^` signifie tout autre chose. Quoi ?

- Une seconde forme est réalisée par le *look-ahead* négatif. Par exemple,  $(?! = ^{\mathcal{R}_2} \$)^{\mathcal{R}_1} \$$  représente le langage  $\mathcal{L}_1$  privé des mots du langage  $\mathcal{L}_2$ , si  $\mathcal{R}_1$  décrit  $\mathcal{L}_1$  et  $\mathcal{R}_2$  décrit  $\mathcal{L}_2$ .

Contrairement à la précédente elle permet réellement de soustraire un langage à un autre.

### 3. Que signifie '\\\\' ? Pourquoi ?

\\\\ signifie \. Pourquoi ? La chaîne de caractères dans laquelle se trouve \\\ est d'abord lue par l'analyseur syntaxique de Java, pour qui \ est un caractère d'échappement. Il en résulte que l'analyseur comprend \\. Quand cette chaîne est lue par une méthode de `regex`, celle-ci voit \ car pour elle \ est aussi un caractère d'échappement.

Se rappeler qu'un caractère d'échappement joue en général deux rôles :

- Donner un sens particulier à un caractère ordinaire : ex. `\n` ou `\t` pour les chaînes de caractères et `\d` ou `\w` pour les `regex`.
- Donner son sens littéral à un caractère qui a un sens particulier : ex. `\"` et `\\` pour les chaînes de caractères et `\(` ou `\\` pour les `regex`.

### 4. Rappelez les quantificateurs que vous avez utilisés. Décrivez chacun d'entre eux brièvement.

Normalement, vous avez dû utiliser les quantificateurs suivants :

- `*` : qui représente l'étoile de Kleene ;
- `+` : qui représente l'étoile de Kleene strictement positive ;
- `?` : qui représente le fait d'être optionnel.
- `{n,m}` : qui représente un produit entre  $n$  fois et  $m$  fois d'un même langage.

**Soit l'alphabet  $\Sigma = \{ -, A, B \}$ . Soit  $\mathcal{L}_{\text{althères}}$  le langage des mots qui commencent par A, finissent par B, contiennent au moins un '-', et où tous les '-' sont collés entre eux. Soit  $\mathcal{L}_{\text{brochettes}}$  le langage des mots qui commencent par '-', finissent par '-', et où tous les '-' forment des groupes de longueur impaire, et où les groupes de lettre commencent par A et finissent par B.**

### 5. Proposez des exemples et des contre-exemples pour $\mathcal{L}_{\text{althères}}$ et pour $\mathcal{L}_{\text{brochettes}}$ .

$\mathcal{L}_{\text{althères}}$  : C (pas dans  $\Sigma^*$ ), B-B (ne commence pas par A), AB (ne contient pas au moins un '-'), A-B-B (les '-' ne sont pas collés entre eux) constituent des contre-exemples, et A-B, ABA---BAB des exemples.

$\mathcal{L}_{\text{brochettes}}$  : = (pas dans  $\Sigma^*$ ), AB (ne commence pas par '-'), --AB- (les '-' ne forment pas tous des groupes de longueur impaire), -AA- (le groupe de lettres ne finit pas par B) constituent des contre-exemples, et -, -AB-, -ABB-, ---AB---ABAAB- des exemples.

Noter que - est bien une brochette. Lire et relire la consigne.

Noter qu'il n'y a pas de fin à une liste d'exemples et des contre-exemples, mais qu'il y a des exemples et des contre-exemples plus intéressants que d'autres ; il faut donc se contenter des plus intéressants. L'essentiel est de couvrir tous les points de la consigne, en ne les respectant pas pour les contre-exemples, et en les respectant pour les exemples. Pour les contre-exemples, il est plus lisible que chaque contre-exemple ne montre le non-respect que d'un point de la consigne.

**6. Proposer une expression régulière pour  $\mathcal{L}_{\text{althères}}$ .**

$A[AB]^* - +[AB]^*B$  est une telle expression régulière.

**7. Proposer une expression régulière pour  $\mathcal{L}_{\text{brochettes}}$ .**

$(-(--)^*A[AB]^*B)^*-(--)^*$

On retrouve une fois de plus les trucs  $(-(--)^*)$  séparés par les machins  $(A[AB]^*B)$ .

**8. On souhaite préciser que les mots de  $\mathcal{L}_{\text{brochettes}}$  ont au moins 2 groupes de lettres, mais pas plus de 5. Proposer une expression régulière pour cette variante.**

$(-(--)^*A[AB]^*B)\{2,5\}-(--)^*$

En gras la seule différence avec la réponse à la question 7.

Se rappeler que dans « trucs séparés par des machins » les trucs sont comme des piquets, et les machins sont comme des traverses entre les piquets ; il y a toujours un piquet de plus que de traverses. Donc un truc de plus que de machins !

**9. On souhaite préciser que les séquences de '-' de  $\mathcal{L}_{\text{althères}}$  sont d'une longueur impaire mais pas multiple de 3. Proposer une expression régulière pour cette variante.**

$A[AB]^*-(--)^*[AB]^*B$

pour dire que les groupes de '-' sont de longueur impaire, et

$(! = ^[AB]^*(----)^+[AB]^*\$)A[AB]^*-(--)^*[AB]^*B$

pour dire que cette longueur n'est pas multiple de 3.

**10. Expliquez à un stagiaire votre solution à la question 9.**

Vous :

« Il faut penser en termes de « les P sauf les Q », qu'on écrira  $(! = ^\mathcal{R}\mathcal{E}_Q\$)\mathcal{R}\mathcal{E}_P$ . C'est le même principe que EXCEPT ou MINUS en SQL. Vas-y, je te laisse faire. »

Le stagiaire :

«

*Pour les P : les altères dont la barre est de longueur impaire. C'est-à-dire comme --- , donc (---)+ ...*

»

Vous :

«

*Ne dis pas de bêtise ! (---)+ signifie toute autre chose : des longueurs multiples de 3, donc 3, 6, etc., qui sont paires ou impaires. C'est  $-(--)*$  qui décrit les longueurs impaires !*

*Donc,  $A[AB]*-(--)*[AB]*B$  pour les altères avec leurs poids.*

»

Le stagiaire :

«

*Oops !*

*Pour les Q : les altères dont la barre est de longueur multiple de 3. C'est justement mon erreur, donc (---)+. Donc,  $A[AB]*(---)+[AB]*B$  pour les altères avec leurs poids.*

»

Vous :

«

*Attention ! Dans l'expression de Q il n'est pas nécessaire de rappeler les contraintes qui pèsent sur les blocs de lettres car elles sont exprimées dans l'expression de P. Par contre, il est nécessaire que tous les '-' soient vus par (---)+. L'expression  $.*(---)+.*$  n'est donc pas acceptable pour Q car elle décrit  $A-----B$  qui n'est pas fautif, mais l'expression  $[AB]*(---)+[AB]*$  marche bien, et elle est un peu plus simple que la tienne.*

»

Le stagiaire :

«

*OK, c'est quand même un peu subtil.*

»

Vous :

«

*Appelle ça comme tu veux, mais c'est ta responsabilité que ça marche !*

*Il reste une chose importante : Il faut vraiment s'assurer que tout ce qui est lu par  $\mathcal{RE}_P$  est bien vérifié par  $\mathcal{RE}_Q$ . C'est pourquoi on a utilisé les délimiteurs ^ et \$ dans le schéma général. Avec plus d'information sur le contexte on aurait pu utiliser d'autres délimiteurs, mais ici on a fait comme en TP.*

»